

郭一驹

电话: (+86) 152-7355-0908 | yijuguo@ruc.edu.cn | yijuguo.github.io



教育经历

中国人民大学 人工智能学院 · 人工智能 · 博士 2022.09 – 至今
GPA: 3.94/4.0 | 清华大学自然语言处理实验室 (THUNLP) 联合培养 北京
大连理工大学 国际信息与软件学院 · 数字媒体技术 (计算机类) · 本科 2017.09 – 2022.07
GPA: 4.02/5.0 (90.02/100) | 综合排名 1/99 | 成绩排名 2/99 大连
荣誉: 大连市优秀毕业生 · 国家奖学金 (×2) · 学习优秀一等奖学金 (×3) · 科技创新奖学金 (×3)

专业技能

大模型训练与对齐: 具备 LLM 核心开发流程的实践经验, 包括监督微调 (SFT)、标准蒸馏, 以及 DPO、GRPO 等偏好优化与强化学习算法的改进与实现。
主流强化学习框架: 深度理解并熟练使用 VeRL、OpenRLHF 等分布式强化学习框架; 能够针对 DPO、GRPO 等算法进行超参数调优及训练效率优化。

主要论文发表

- Yiju Guo**, Tianyi Hu, Zexu Sun, Yankai Lin. “Less Noise, More Voice: Reinforcement Learning for Reasoning via Instruction Purification.” **ACL 2026**
- Yiju Guo**, Wenkai Yang, Zexu Sun, Ning Ding, Zhiyuan Liu, Yankai Lin. “Learning to Focus: Causal Attention Distillation via Gradient-Guided Token Pruning.” **NeurIPS 2025**
- Yiju Guo***, Ganqu Cui*, Lifan Yuan, Ning Ding, Zexu Sun, Bowen Sun, Huimin Chen, Ruobing Xie, Jie Zhou, Yankai Lin, Zhiyuan Liu, Maosong Sun. “Controllable Preference Optimization: Toward Controllable Multi-Objective Alignment.” **EMNLP 2024** (120 citations)
- Zexu Sun, **Yiju Guo**, Yankai Lin, Xu Chen, Qi Qi, Xing Tang, Ji-Rong Wen. “Uncertainty and Influence Aware Reward Model Refinement for RLHF.” **ICLR 2025**
- Wenkai Yang, Weijie Liu, Ruobing Xie, **Yiju Guo**, Lulu Wu, Saiyong Yang, Yankai Lin. “LaSeR: RL with Last-Token Self-Rewarding.” **ICLR 2026**

实习经历

百度 百度搜索 · 研究实习生 2025.09 – 2026.01
负责人: 苏立新, 殷大为
主导基于指令去噪的大语言模型强化学习优化方面的研究, 作为第一作者撰写论文《Less Noise, More Voice: Reinforcement Learning for Reasoning via Instruction Purification》, 被 **ACL 2026** 录用。

面壁智能 大语言模型安全对齐组 · 研究实习生 2024.05 – 2025.05
负责人: 丁宁, 刘知远
主导了基于因果推理与蒸馏的大语言模型推理能力强化研究, 并作为第一作者撰写论文《Learning to Focus: Causal Attention Distillation via Gradient-Guided Token Pruning》, 被 **NeurIPS 2025** 录用。

腾讯 微信事业部 · 研究实习生 2022.09 – 2024.04
负责人: 谢若冰, 周杰
主导大语言模型可控多目标对齐研究, 作为第一作者发表论文《Controllable Preference Optimization: Toward Controllable Multi-Objective Alignment》, 被 **EMNLP 2024** 录用, 引用达 120 次。

项目经历

基于指令去噪的大语言模型强化学习优化 (ACL 2026 录用)

2025.07 – 2026.01

第一作者 | THUNLP & RUCBM | 导师: 林衍凯 | 主导数据构造、方法及实验设计、论文写作

北京

- 强化学习复杂推理任务中, 由于大量问题采样成功率极低乃至为零, 极易导致训练收敛缓慢甚至坍塌。分析发现, 许多探索失败并非源于题目难度, 而是提示词中存在极少量的干扰词元带偏推理方向。
- 设计并实现了 **LENS** 两阶段指令去噪框架。第一阶段**干扰 Token 识别与净化**: 通过量化策略模型与参考模型的 Token 级偏差 (Interference Score), 精准剔除误导推理的干扰词元, 将单 batch 采样成功率提升约 **20%**。第二阶段**校准采样策略优化**: 将去噪指令下的成功推理链作为监督信号, 校准原始噪声指令下的策略更新, 提升真实场景中指令干扰下的推理鲁棒性。
- 在 Llama-3.2、Qwen-2.5/3 等模型上, 于 MATH-500、AMC23、OlympiadBench 等 **7** 个数学基准测试中, 平均性能提升 **3.88%**, 实现了约 **1.6 倍** 的收敛加速, 并优于**扩大探索量**的 GRPO 和**提示过滤** (DAPO、GRESO) 等基线方法。该方法可集成至现有 RL 训练流程, 从而缓解 RLVR 熵坍塌问题。

基于因果推理与蒸馏的大语言模型推理能力强化 (NeurIPS 2025 录用)

2024.05 – 2025.05

第一作者 | THUNLP & RUCBM | 导师: 林衍凯 | 主导方法及实验设计、数据分析、论文写作

北京

- 通过对比 LLaMA-70B 与 LLaMA-1B 的 Token 级梯度差异发现, **小模型推理失败往往源于过度关注干扰 Token 而忽略关键 Token**。基于此发现, 仅删除小模型过度关注但大模型忽略的干扰 Token, 即可在数学和代码任务上分别提升 **20%** 和 **10%** 的准确率。
- 提出 **Learning to Focus (LeaF)** 两阶段因果蒸馏框架: 第一阶段**干扰词元检测**: 通过教师与学生模型的梯度比较, 量化并剔除训练语料中的干扰 Token, 构建高质量反事实样本; 第二阶段**因果注意力蒸馏**: 通过对比原始样本与反事实样本的输出差异进行**因果注意力蒸馏**, 引导学生模型学习真实因果依赖关系, 将注意力从干扰信息转移至关键的推理信息。
- 在 LLaMA3.2-1B/3B-Instruct 和 Qwen2.5-Math-1.5B 上, 相比普通蒸馏, 在**数学推理任务** (GSM8K、MATH、OlympiadBench) 提升 **2.41%**, **代码生成任务** (HumanEval+、LeetCode、LiveCodeBench) 提升 **2.48%**, **多跳推理任务** (2WikiMQA、Musique、HotpotQA) 提升 **3.24%**。可解释性实验进一步表明 LeaF 有效增强了模型对关键信息的关注能力, 从而提升大语言模型的推理能力。

大语言模型多目标对齐与可控偏好优化算法研究 (EMNLP 2024 录用)

2023.09 – 2024.04

第一作者 | THUNLP & RUCBM | 导师: 林衍凯 | 主导数据构造、方法及实验设计、论文写作

北京

- 针对大语言模型多目标对齐中的**对齐税**问题——**对单一目标 (如安全性) 的优化往往导致其他目标 (如有用性) 性能下降**, 创新性地引入**多目标偏好标记 (preference token)** 确定优化方向 (如有用性、诚实性等), 将多目标优化问题转化为**条件化的多目标优化**问题, 实现了对不同目标的可控优化。
- 提出**可控偏好优化 (CPO)** 算法, 包含两阶段: **CPSFT** 阶段通过偏好控制 Token 引导模型学习生成符合指定偏好条件的回答; **CDPO** 阶段改进传统 DPO 对各维度分数直接加和的做法, 在控制特定维度偏好趋近用户设定值的同时, 最大化其余维度的偏好, 从而有效降低目标间冲突。
- 实验表明, CPO 在**多目标对齐 (有用性、诚实性、无害性)** 上全面超越传统方法 (SFT、PPO、DPO、Curry-DPO), 实现可控性与整体性能的双重提升。同时构建并开源 **UltraSafety** 数据集, 弥补 UltraFeedback 在安全维度的数据空缺。

研究兴趣

强化学习与大语言模型对齐 (RLHF): 专注于 GRPO、DPO、PPO 等对齐算法的优化。

大模型在线经验学习与自主进化: 研究智能体如何从交互轨迹中筛选可迁移经验, 探索基于动态价值估计的筛选机制与策略模型协同进化, 提升在线学习的多轮迭代稳定性与样本效率。

Agentic RL 中的贡献分配优化: 当前智能体强化学习中的奖励信号稀疏且分配不够精准, 难以有效识别关键推理步骤的贡献, 导致大量采样数据被浪费。探索更精确的细粒度贡献分配方法, 提升训练信号质量, 从而促进 Agentic RL 的训练稳定性与样本效率。